Documento Explicativo — Inciso C: Comparación Exhaustiva Red Densa vs CNN en Fashion-MNIST

Curso / Materia: Redes Neuronales / Internet de las Cosas
Estudiante / Autor: Práctica Académica Reproducible
Entorno de Ejecución: Python 3.10 / TensorFlow 2.21 / Keras 3.12 / NumPy 2.2 / Matplotlib 3.10
Dispositivo de Cómputo: CPU Intel/AMD (x86_64 con aceleración oneDNN)
Semilla Aleatoria Global: 42

1. Ficha Técnica y Tabla Comparativa Formal (Pasos 1, 7 y 11)

A continuación se presenta la tabla comparativa con los valores exactos registrados durante la ejecución experimental bajo condiciones estrictamente idénticas:

Métrica / Parámetro de Evaluación	Red Densa (MLP)	Red Convolucional (CNN)	Diferencia Absoluta (CNN vs Dense)	Impacto Relativo
Arquitectura	Input(28,28) $\to$ Flatten $\to$ Dense(128) $\to$ Dense(64) $\to$ Softmax(10)	Conv2D(32) $\to$ Pool $\to$ Conv2D(64) $\to$ Pool $\to$ Dense(64) $\to$ Softmax(10)	—	Paradigma Convolucional vs Aplanado
Parámetros Entrenables	**109,386** (427.29 KB)	**121,930** (476.29 KB)	**+12,544**	**+11.5%** más parámetros
Tiempo de Entrenamiento (10 épocas)	**38.14 s** (3.81 s/época)	**131.19 s** (13.12 s/época)	**+93.04 s**	**3.44 veces más lenta** en CPU
Loss en Entrenamiento (Época 10)	0.2365	0.1536	-0.0829	Mayor ajuste en train
Exactitud en Entrenamiento (Train Acc)	91.31%	94.56%	+3.25%	Mayor capacidad de memoria local
Loss en Validación (Val Loss)	0.3421	0.3455	+0.0034	Niveles prácticamente equivalentes
Exactitud en Validación (Val Acc)	88.56%	88.92%	+0.36%	Ligera ventaja inicial
Pérdida en Test (Test Loss)	**0.3734**	**0.3674**	**-0.0059**	Mejor calibración de pérdida en CNN
Exactitud en Test (Test Accuracy)	**87.28%**	**88.55%**	**+1.27%**	**Ganadora en precisión (+127 aciertos)**
Total de Errores en Test (de 10,000)	**1,272 fallos**	**1,145 fallos**	**-127 fallos**	**-10.0% de reducción de error**

Métrica / Parámetro de Evaluación	Red Densa (MLP)	Red Convolucional (CNN)	Diferencia Absoluta (CNN vs Dense)	Impacto Relativo
Brecha Generalización (Train - Test)	+4.03%	+6.01%	+1.98%	Mayor tendencia al sobreajuste en CNN
Brecha Estabilidad (Val - Test)	+1.28%	**+0.37%**	-0.91%	**Validación de CNN más fiel al Test real**

---

2. Descripción y Exploración del Dataset Fashion-MNIST (Paso 2)

Fashion-MNIST (*Xiao, Rasul & Vollgraf, Zalando Research, 2017*) fue diseñado específicamente como un sustituto directo y más exigente del clásico MNIST de dígitos manuscritos. Comparte idénticas dimensiones espaciales (28×28 píxeles en escala de grises), número de clases (10) y tamaño de partición ($60,000$ entrenamiento, $10,000$ prueba).

2.1. Las 10 Categorías en Español

Las categorías están codificadas numéricamente del 0 al 9:
0. **Camiseta / top** (*T-shirt/top*)
1. **Pantalón** (*Trouser*)
2. **Pulóver** (*Pullover*)
3. **Vestido** (*Dress*)
4. **Abrigo** (*Coat*)
5. **Sandalia** (*Sandal*)
6. **Camisa** (*Shirt*)
7. **Tenis / zapatilla** (*Sneaker*)
8. **Bolso** (*Bag*)
9. **Botín** (*Ankle boot*)

2.2. Dificultad Morfológica

A diferencia de los dígitos (que consisten esencialmente en trazos lineales blancos aislados sobre fondo negro), las prendas de Fashion-MNIST presentan:
- Texturas continuas, estampados, patrones de tejido y gradientes sutiles.
- Pliegues tridimensionales en la ropa.
- Gran similitud visual intraclase e interclase entre prendas superiores (camisetas, camisas, abrigos y pulóveres comparten contornos corporales similares).

3. Preprocesamiento y Diseño Experimental Controlado (Pasos 3 y 6)

Para que la comparativa sea estrictamente metodológica, se anularon todas las fuentes externas de varianza:
1. **Normalización:** Los píxeles originales enteros en $[0, 255]$ se reescalaron dividiendo entre 255.0, obteniendo valores de punto flotante en $[0.0, 1.0]$.
2. **Partición Idéntica:** De las $60,000$ imágenes de entrenamiento, se reservaron exactamente $50,000$ para entrenamiento activo y $10,000$ para validación mediante permutación aleatoria con semilla 42.
3. **Formas de Tensor:**
- **Para la Red Densa:** Entrada en formato bidimensional $(N, 28, 28)$ procesada internamente mediante una capa `Flatten()` que colapsa los píxeles a un vector 1D de 784 componentes.
- **Para la Red CNN:** Entrada en formato tensorial 4D $(N, 28, 28, 1)$ añadiendo explícitamente el canal de profundidad.
4. **Hiperparámetros de Entrenamiento:**
- Épocas: **10**
- Tamaño de lote: **64** (782 pasos de gradiente por época)
- Optimizador: **Adam** ($\alpha = 0.001$)
- Función de coste: `sparse_categorical_crossentropy`

4. Arquitectura de los Modelos (Pasos 4 y 5)

4.1. Red Densa (Multilayer Perceptron - MLP)

```
model_dense = keras.Sequential([
    keras.layers.Input(shape=(28, 28), name="entrada_28x28"),
    keras.layers.Flatten(name="aplanado_784"),
    keras.layers.Dense(128, activation='relu', name="densa_128_relu"),
    keras.layers.Dense(64, activation='relu', name="densa_64_relu"),
    keras.layers.Dense(10, activation='softmax', name="salida_10_softmax")
], name="Fashion_Dense_MLP")
```

- **Conexiones:**
- $784 \to 128$: $784 \times 128 + 128 = 100,480$ parámetros.
- $128 \to 64$: $128 \times 64 + 64 = 8,256$ parámetros.
- $64 \to 10$: $64 \times 10 + 10 = 650$ parámetros.
- **Total de Parámetros: 109,386**.

4.2. Red Convolucional (CNN)

```
model_cnn = keras.Sequential([
    keras.layers.Input(shape=(28, 28, 1), name="entrada_tensor_28x28x1"),
    keras.layers.Conv2D(32, kernel_size=(3, 3), activation='relu', name="conv2d_32_3x3"),
    keras.layers.MaxPooling2D(pool_size=(2, 2), name="maxpool_1"),
    keras.layers.Conv2D(64, kernel_size=(3, 3), activation='relu', name="conv2d_64_3x3"),
    keras.layers.MaxPooling2D(pool_size=(2, 2), name="maxpool_2"),
    keras.layers.Flatten(name="aplanado"),
    keras.layers.Dense(64, activation='relu', name="densa_64_relu"),
    keras.layers.Dense(10, activation='softmax', name="salida_10_softmax")
], name="Fashion_CNN")
```

- **Conexiones:**
- `Conv2D(32, 3x3)`: $3 \times 3 \times 1 \times 32 + 32 = 320$ parámetros $\to$ mapa $(26, 26, 32)$.
- `MaxPooling2D(2x2)`: 0 parámetros $\to$ mapa $(13, 13, 32)$.
- `Conv2D(64, 3x3)`: $3 \times 3 \times 32 \times 64 + 64 = 18,496$ parámetros $\to$ mapa $(11, 11, 64)$.
- `MaxPooling2D(2x2)`: 0 parámetros $\to$ mapa $(5, 5, 64)$.
- `Flatten()`: $5 \times 5 \times 64 = 1,600$ rasgos espaciales.
- `Dense(64)`: $1,600 \times 64 + 64 = 102,464$ parámetros.
- `Dense(10)`: $64 \times 10 + 10 = 650$ parámetros.
- **Total de Parámetros: 121,930**.

---

5. Curvas Comparativas de Aprendizaje (Paso 8)

Las curvas generadas en `evidencias/C/paso8_curvas_comparativas.png` exhiben dos comportamientos clave:

1. **Velocidad de Aprendizaje en Entrenamiento:**
2. La CNN aprende más rápido y con mayor profundidad en el set de entrenamiento: en la época 2 ya alcanza 87.5% (frente al 85.9% de la Dense) y en la época 10 llega al 94.56% con una pérdida de 0.1536 (frente al 91.31% y 0.2365 de la Dense).
3. **Dinámica de Validación y Punto de Inflexión:**
4. **Red Densa:** Su pérdida de validación desciende de 0.430 a 0.329 en la época 7, antes de estabilizarse en torno a 0.342. Su exactitud de validación evoluciona de forma muy constante hasta 88.56%.
5. **Red CNN:** Su pérdida de validación desciende con mayor fuerza hasta un mínimo de 0.281 en la época 6 (exactitud de validación de 89.94%). Posteriormente, a partir de la época 7, la pérdida de validación comienza a subir suavemente hacia 0.345, indicando que el modelo convolucional comienza a sobreajustar los detalles minuciosos del set de entrenamiento.

6. Análisis de Matrices de Confusión y Categorías Críticas (Paso 9)

6.1. Desglose Detallado de Errores por Categoría (1,000 imágenes por clase en Test)

Categoría	Errores en Red Densa	Tasa de Error Densa (%)	Errores en Red CNN	Tasa de Error CNN (%)	Diferencia en Fallos (CNN vs Dense)
Camiseta / top	166	16.6%	284	28.4%	+118 fallos
Pantalón	30	3.0%	25	2.5%	-5 fallos
Pulóver	179	17.9%	217	21.7%	+38 fallos
Vestido	79	7.9%	71	7.1%	-8 fallos
Abrigo	287	28.7%	194	19.4%	**-93 fallos**
Sandalia	68	6.8%	107	10.7%	+39 fallos
Camisa	321	32.1%	151	15.1%	**-170 fallos (¡Reducción del 53%!)**
Tenis / zapatilla	19	1.9%	6	0.6%	**-13 fallos (99.4% acierto)**
Bolso	49	4.9%	21	2.1%	**-28 fallos**
Botín	74	7.4%	69	6.9%	-5 fallos
TOTAL	**1,272**	**12.72%**	**1,145**	**11.45%**	**-127 fallos netos**

6.2. Hallazgo Cualitativo Fundamental

El impacto más dramático de la arquitectura convolucional se produjo en la **Camisa (*Shirt*, clase 6)**:
- Para la Red Densa, la camisa fue casi imposible de distinguir: cometió **321 errores de 1,000 imágenes** (confundiéndose masivamente con camisetas, abrigos y pulóveres).
- La CNN logró discriminar los cuellos abotonados y las costuras de las mangas gracias a sus filtros de bordes locales, reduciendo los errores a **151 (recorte del 53% en fallos)**.
- De igual modo, en **Abrigos (*Coat*, clase 4)**, la CNN recortó los fallos de 287 a 194.
- En calzado deportivo (**Tenis**, clase 7), la CNN prácticamente rozó la perfección: **solo 6 equivocaciones en 1,000 muestras**.

7. Muestras Mal Clasificadas (Paso 10)

En las evidencias `evidencias/C/paso10_errores_dense.png` y `paso10_errores_cnn.png`:
- **Red Densa:** Confunde de forma recurrente abrigos largos con vestidos, y camisas de manga corta con camisetas estándar, con probabilidades de Softmax superiores al 80%.
- **Red CNN:** Los fallos restantes ocurren en casos genuinamente ambiguos para el ojo humano: una sandalia con tiras altas muy tupidas clasificada como tenis ($P=82\%$), o un pulóver holgado con cuello en V clasificado como abrigo.

---

8. Respuestas Argumentadas a las Preguntas Guía (Paso 12)

1. ¿Cuál modelo obtuvo mayor exactitud en prueba?

La Red Convolucional (CNN) obtuvo la mayor exactitud con un **88.55%** (1,145 errores), superando a la Red Densa que alcanzó **87.28%** (1,272 errores). La CNN redujo en **127 los errores absolutos** (un 10% menos de equivocaciones).

2. ¿Cuál demostró mejor generalización en prueba?

- **Pérdida en Test:** La CNN obtuvo una menor pérdida (**0.3674** vs **0.3734** de la Dense).
- **Consistencia Validación-Test:** La exactitud de validación de la CNN (88.92%) estuvo a tan solo **+0.37%** de su exactitud de prueba (88.55%), mientras que en la Red Densa la brecha fue de **+1.28%**. Esto demuestra que la validación en la CNN refleja con mayor fidelidad su rendimiento real generalizado.
- **Sobreajuste:** En las épocas 7 a 10, la CNN exhibió un descenso continuo en la pérdida de entrenamiento mientras la de validación comenzó a rebotar levemente, sugiriendo que la inclusión de técnicas de regularización (como *Dropout(0.25)* o aumento de datos sintético) permitiría a la CNN superar cómodamente el 91-92% de exactitud.

3. ¿Cuál modelo tiene mayor cantidad de parámetros?

La CNN tiene más parámetros: 121,930 frente a **109,386** (+12,544 parámetros, +11.5%). La mayor parte de los parámetros de la CNN se concentran en la capa densa de transición tras el aplanado ($1600 \times 64 = 102,464$), mientras que sus capas convolucionales son sumamente eficientes ($18,816$ pesos para procesar toda la imagen).

4. ¿Cuál requirió mayor tiempo de entrenamiento?

La CNN requirió sensiblemente más tiempo: 131.19 segundos frente a **38.14 segundos** de la Red Densa (**3.44 veces más lenta** en CPU). Las operaciones de convolución involucran millones de multiplicaciones y sumas en ventanas deslizantes 2D, las cuales son computacionalmente mucho más intensivas en procesadores convencionales sin unidades tensoriales aceleradoras (TPU/GPU).

5. ¿Qué diferencias principales se observan en las matrices de confusión?

La Red Densa fracasa rotundamente en discriminar entre prendas superiores con mangas (321 fallos en camisas y 287 en abrigos). La CNN disminuye notablemente estas confusiones gracias a la extracción jerárquica de características (botones, cuellos, dobladillos).

6. ¿Por qué la arquitectura CNN suele ser superior para imágenes?

1. **Conectividad Local:** Cada filtro opera sobre una ventana reducida (3×3), capturando correlaciones espaciales coherentes con la física de la luz y las superficies.
2. **Pesos Compartidos (*Weight Sharing*):** El mismo filtro detector de texturas o líneas diagonales se reutiliza en todos los cuadrantes de la imagen.
3. **Invarianza Traslacional:** El agrupamiento (*max pooling*) confiere tolerancia a desplazamientos menores: una camisa situada ligeramente hacia la izquierda activa los mismos mapas de rasgos que una camisa centrada. La Red Densa carece de esta propiedad: al aplanar los píxeles a un vector 1D, cualquier traslación de 2 píxeles altera la posición de todos los valores de entrada.

---

9. Conclusión Académica Final (Paso 13)

El estudio experimental demuestra que **el diseño arquitectónico tiene un impacto directo y medible en el rendimiento de un sistema de visión artificial**:
- La **Red Convolucional (CNN)** superó sistemáticamente a la **Red Densa**, reduciendo los errores en un **10.0%** y mitigando las ambigüedades en las prendas más complejas (camisas y abrigos).
- Sin embargo, esta superioridad no es gratuita: requirió un **344% más de tiempo de entrenamiento en CPU**.
- En consecuencia, en entornos de cómputo restringido o en dispositivos del Internet de las Cosas (IoT) con baterías limitadas, la elección entre un modelo denso y uno convolucional debe sustentarse en un análisis riguroso de la relación **costo computacional vs. ganancia en exactitud**.